

Proyecto JARVIS — Plan de Diseño e Implementación

Asistente de voz local para Windows 11. Se activa por palmadas o wake word, entiende órdenes en español y ejecuta acciones sobre el sistema, tus tareas y Spotify.

Fecha: 2026-08-20 **Autor:** Rafael Chu (@RafaelCly) **Presupuesto:** \$5 USD de créditos OpenAI — única inversión monetaria **Estado:** Diseño aprobado, pendiente de implementación

1. Resumen ejecutivo

Jarvis es un proceso Python que corre permanentemente en segundo plano escuchando el micrófono. Detecta dos tipos de activación (una palmada doble, o la frase "oye Jarvis"), transcribe lo que dices, decide qué hacer, lo hace, y te responde hablando.

La decisión arquitectónica central es **local-first**: todo el procesamiento de audio —detección de palmadas, wake word, transcripción y síntesis de voz— corre en tu máquina. La nube solo interviene para una cosa: convertir una frase en español a una llamada de función. Esto tiene tres consecuencias directas:

- 1. **Costo casi nulo.** OpenAI nunca ve audio, solo texto corto. ~\$0.0002 por comando.
- 2. **Latencia baja.** No hay que subir audio ni esperar streaming de vuelta.
- 3. **Privacidad.** Tu micrófono no sale de tu PC salvo la frase ya transcrita.

Principio de diseño no negociable

El LLM nunca ejecuta código. Solo elige el nombre de una función de una lista fija y rellena parámetros que después se validan.

Esto no es paranoia: Jarvis escucha todo lo que suena en la habitación, incluido un video de YouTube o alguien de visita. Si el modelo pudiera generar comandos de shell, cualquier audio en el cuarto sería una superficie de ataque. Por eso: nada de `exec`, nada de `os.system` con strings del modelo, sin herramientas destructivas en el catálogo, y operaciones de archivos restringidas a una lista blanca de carpetas.

2. Hardware verificado

Estas specs fueron leídas de la máquina, no estimadas:

Componente	Valor	Implicación
CPU	Intel i7-12650H (10C / 16T)	Sobra para audio en tiempo real
RAM	15.7 GB	Sin problema

Componente	Valor	Implicación
GPU	NVIDIA RTX 4050 Laptop, 6 GB VRAM (driver 610.74)	Whisper en GPU: transcripción en ~300 ms
Python	3.11, 3.13 y 3.14 disponibles	Usar 3.11 — mejor compatibilidad de wheels
Micrófonos	Array Intel Smart Sound (interno) + Redmi Buds 6 Play	Ver advertencia abajo

La conclusión que importa: **esta máquina aguanta todo el pipeline de voz en local**. Whisper corre en GPU, así que la transcripción no cuesta dinero ni latencia de red, y los \$5 de OpenAI quedan enteros para el cerebro.

Advertencia crítica: no usar auriculares Bluetooth como micrófono

Bluetooth no puede transmitir audio de alta calidad y capturar micrófono al mismo tiempo. Cuando se activa el micrófono de unos auriculares BT, Windows conmuta el perfil de A2DP (estéreo, alta calidad) a **HFP/Hands-Free** (mono, 8-16 kHz). Resultado: cada vez que Jarvis te escuche, la música de Spotify se degrada a calidad de radio de taxi.

Configuración obligatoria: entrada = array interno del laptop, salida = lo que quieras.

Ajustes de máquina: config.local.yaml

config.yaml está commiteado. Pero el índice del micrófono y el device de Whisper son propios de esta computadora, y el repo es público: no tiene sentido versionarlos.

Van en config.local.yaml, que está en .gitignore y cuyos valores pisan a los del compartido. Hay una plantilla en config.local.yaml.example.

3. Presupuesto real

Lo que cuesta dinero

Ítem	Costo	Obligatorio
Créditos OpenAI	\$5 USD (único)	Sí
TOTAL	\$5 USD	

Cuánto duran los \$5

Con gpt-4o-mini a \$0.15 por millón de tokens de entrada y \$0.60 de salida, y un prompt típico de ~1,200 tokens de entrada (system prompt + definiciones de herramientas) más ~80 de salida:

$$(1200 * 0.15 / 1_000_000) + (80 * 0.60 / 1_000_000) = \sim \$0.00023 \text{ por comando}$$
$$\$5.00 / \$0.00023 = \sim 21,000 \text{ comandos}$$

A 30 comandos diarios, eso es **cerca de 2 años**. Y con el router de reglas (\$5.2) los comandos frecuentes ni siquiera tocan la API, así que el número real será bastante mayor. El *prompt caching* de OpenAI abarata todavía más la parte fija del prompt.

¿Basta gpt-4o-mini? Sí, holgadamente. La tarea es clasificación de intención con extracción de parámetros — de lo más fácil que hace un LLM. Un modelo de gama alta acá sería desperdiciar dinero sin ganar nada perceptible.

Verificar antes de cargar los créditos: el catálogo de OpenAI rota seguido. Revisá la página de pricing por si existe un modelo `mini` más nuevo o más barato. Cualquier modelo de gama "mini" con soporte de *tool calling* sirve — no cambia ni una línea de la arquitectura, solo el string en `config.yaml`.

Lo que es gratis

`openWakeWord` (Apache-2.0) · `faster-whisper` (MIT) · `Piper TTS` (MIT) · `silero-vad` (MIT) · `sounddevice` (MIT) · `spotipy` (MIT) · `Everything` de voidtools (freeware) · `pycaw` (MIT) · `winsdk` (MIT)

Costo no monetario: ~2-3 GB de disco para los modelos de Whisper, wake word y Piper.

El asterisco: Spotify Free

La Web API de Spotify devuelve **HTTP 403 PREMIUM_REQUIRED** en todos los endpoints de control de reproducción. No es un bug ni algo que se pueda rodear con código: es una restricción comercial de Spotify. Con cuenta Free hay que entrar por otra puerta.

Acción	Con Premium (API directa)	Plan B con Free (el que usaremos)
Buscar canción	<code>sp.search()</code>	<code>sp.search()</code> — funciona igual en Free , usa Client Credentials y no requiere login de usuario
Reproducir un track	<code>sp.start_playback(uris=[...])</code>	<code>os.startfile("spotify:track:<id>")</code> — la app de escritorio lo abre y lo reproduce
Play / pausa / siguiente	<code>sp.pause_playback()</code>	SMTC vía <code>winsdk</code> , dirigido a la sesión de Spotify
Volumen	<code>sp.volume(70)</code>	<code>pycaw</code> — volumen del proceso <code>Spotify.exe</code> aisladamente
"¿Qué está sonando?"	<code>sp.current_playback()</code>	SMTC <code>get_media_properties_async()</code> → título, artista, estado

Sobre SMTC: Windows expone `GlobalSystemMediaTransportControlsSessionManager`, la API que alimenta el panel multimedia del sistema. Permite enumerar sesiones, filtrar la de Spotify por su `AppUserModelId`, y enviarle comandos *dirigidos*. Es mucho más robusto que simular teclas multimedia globales, que se las roba cualquier pestaña del navegador que esté reproduciendo video. Además permite **leer** la canción actual sin tocar la API.

Limitaciones honestas del Plan B: hay anuncios entre canciones, y en cuentas Free Spotify a veces ignora el track exacto y arranca un shuffle de artistas relacionados. No hay forma de evitarlo desde el código.

Mitigación de diseño: una sola interfaz `SpotifyController` con dos implementaciones (`FreeSpotifyController` y `PremiumSpotifyController`). Si algún día alguno se pone Premium, se cambia una línea de config y el resto del sistema no se entera.

4. Stack tecnológico

Capa	Librería	Por qué esta y no otra
Runtime	Python 3.11	3.13/3.14 aún tienen wheels incompletos para <code>onnxruntime</code> y <code>faster-whisper</code> . 3.11 es el punto dulce.
Captura de audio	<code>sounddevice</code> (PortAudio)	API limpia y nativa de numpy. <code>pyaudio</code> está semiabandonado y compila mal en Windows.
Detección de palmadas	numpy puro	No necesita IA. Una palmada es un transitorio de energía; se detecta con DSP básico. Ver §5.3.
Wake word	<code>openWakeWord</code>	Corre en ONNX sobre CPU en ~4 ms. Trae un modelo pre-entrenado de "hey jarvis" — literalmente lo que queremos. Y permite entrenar modelos propios gratis.
VAD (fin de frase)	<code>silero-vad</code>	Bastante más preciso que <code>webrtcvad</code> en ambientes ruidosos, y también es ONNX ligero.
Transcripción	<code>faster-whisper</code> (CTranslate2)	~4x más rápido que el Whisper de referencia con la misma precisión. En la 4050 con <code>float16</code> es prácticamente instantáneo.
Síntesis de voz	Piper TTS	MEDIDO, y el plan original se equivocaba: no son <100 ms sino ~1000 ms para una frase de 2 s (voz <code>medium</code>). No es falta de hilos: con 1, 4 o 10 el tiempo no cambia. <code>edge-tts</code> no mejora (940 ms al primer audio) y encima necesita internet, así que Piper se queda por ser offline. Ver §4.1.
Cerebro	OpenAI SDK + <code>gpt-4o-mini</code> con <code>tool calling</code>	Ver §3.
Validación	<code>pydantic</code>	Los argumentos que devuelve el LLM se validan contra un esquema antes de tocar nada. Esta es la barrera de seguridad.
Búsqueda de archivos	Everything + <code>es.exe</code>	Indexa la MFT de NTFS y responde en milisegundos. Windows Search es lento e inconsistente.
Tareas / pendientes	SQLite (<code>sqlite3</code> , <code>stdlib</code>)	Cero dependencias, cero API keys, funciona offline. Sincronizar con Google Tasks es un extra que no necesitamos ahora.
Spotify	<code>spotipy</code> + <code>winsdk</code> + <code>pycaw</code>	Ver §3.
Config	<code>pydantic-settings</code> + <code>config.yaml</code> + <code>.env</code>	Secretos en <code>.env</code> (gitignored), ajustes en YAML.
Logs	<code>rich</code>	Consola legible con estados y timings, que es lo que más se depura acá.
Interfaz — bandeja	<code>pystray</code>	Icono de estado en la bandeja del sistema. Ver §10.
Interfaz — HUD	<code>pywebview</code> (WebView2)	HUD flotante escrito en HTML/CSS. Fase 4, sujeto a spike. Ver §10.
Tests	<code>pytest</code>	Ver §9.

4.1 Latencia del TTS: la parte más lenta

Medido en el i7-12650H con la frase "Son las tres y cinco de la tarde" (2 s de audio), mediana de varias repeticiones tras calentar:

Voz	Latencia	Comentario
es_MX-claude-high	~1400 ms	La mejor voz
es_MX-ald-medium	~1000 ms	El default. Equilibrio
es_ES-carlrm-x_low	~630 ms	La más rápida, se nota peor
edge-tts (nube)	940 ms al primer audio	No compensa: necesita internet

Esto convierte al TTS en la latencia dominante de la respuesta, por encima de Whisper en GPU (~300 ms). Dos consecuencias de diseño:

- `decir()` reproduce **por trozos**. Piper trocea por oración, así que en una respuesta de varias frases la primera empieza a sonar mientras se genera la segunda. En respuestas de una sola frase no hay nada que ganar.
- Las skills devuelven `speech` **corto**. Cada oración de más son ~500 ms de espera.

La voz se cambia en `config.local.yaml` sin tocar código. Para comparar y escuchar: `py -3.11 tools_probar_voz.py --todas`

requirements.txt inicial

```
sounddevice>=0.4.6
numpy>=1.26
openwakeword>=0.6.0
onnxruntime>=1.17
silero-vad>=5.1
faster-whisper>=1.0
piper-tts>=1.2
edge-tts>=6.1
openai>=1.40
pydantic>=2.7
pydantic-settings>=2.3
spotipy>=2.24
winsdk>=1.0
pycaw>=20240210
pywin32>=306
pyyaml>=6.0
rich>=13.7


# Interfaz (ver §10)
pystray>=0.19      # Fase 2
Pillow>=10.0       # iconos de la bandeja
pywebview>=5.0     # Fase 4, sujeto al spike R9

pytest>=8.0
pytest-asyncio>=0.23

# Solo para Whisper en GPU (ver Riesgo R1)
nvidia-cublas-cu12
nvidia-cudnn-cu12
```

5. Arquitectura

5.1 Flujo de datos



5.2 El router de reglas (por qué existe)

Antes de gastar una llamada al LLM, un matcher de reglas atiende los ~15 comandos más frecuentes: `pausa`, `siguiente`, `sube el volumen`, `qué hora es`, `qué está sonando`.

Son unas 40 líneas de regex más normalización, y compran tres cosas: latencia cero en lo que más se usa, funcionamiento sin internet para lo básico, y menos gasto de créditos. Lo que no matchea sube al LLM, que es donde está la magia de entender *"ponme algo tranquilo para estudiar"* o *"abrí donde tengo los pdfs de la uni"*.


5.3 Detección de palmadas (sin IA)

Una palmada tiene una firma acústica muy distinguible: **transitorio de banda ancha, ataque casi vertical y decaimiento muy rápido**. El algoritmo:

1. Energía RMS por ventana de 10 ms.
2. **Umbral adaptativo**: mediana móvil de los últimos 2 s como piso de ruido. Esto es lo que hace que funcione tanto en silencio como con música de fondo — un umbral fijo fallaría siempre en uno de los dos casos.
3. *Onset* = la energía supera el piso por más de N dB.
4. **Filtro de decaimiento**: debe volver cerca del piso en <80 ms. Esto descarta voz, música y risas, que sostienen energía mucho más tiempo.
5. **Filtro de planitud espectral**: una palmada es ruido de banda ancha. Descarta sonidos tonales (un timbre, una nota).
6. **Doble palmada** = dos onsets separados por 150–600 ms.
7. **Periodo refractario** de 800 ms tras un disparo, para no encadenar detecciones.

Se usa doble palmada y no simple a propósito: una palmada suelta se confunde con un portazo o un golpe en la mesa. Dos con el intervalo correcto casi no ocurren por accidente.

5.4 Máquina de estados



El estado **SPEAKING silencia el detector de wake word.** Sin esto, Jarvis se escucha a sí mismo por los parlantes, se re-dispara y entra en bucle. Es half-duplex: mientras habla, no escucha. Es la solución simple y funciona. La cancelación de eco acústica real (para poder interrumpirlo a media frase) queda como mejora de Fase 4.

5.5 Estructura del proyecto

```
jarvis/
├── core/
│   ├── events.py      ← CONTRATO: dataclasses de eventos
│   ├── bus.py         pub/sub asyncio
│   ├── state.py       máquina de estados
│   └── config.py      pydantic-settings
├── ears/              ← HEMSY
│   ├── capture.py     InputStream + buffer circular
│   ├── clap.py        detector de palmadas
│   ├── wakeword.py     openWakeWord
│   ├── vad.py         silero-vad + endpointing
│   └── stt.py         faster-whisper
├── voice/             ← HEMSY
│   ├── base.py        interfaz TTSEngine
│   ├── piper_tts.py
│   └── edge_tts.py
├── brain/             ← RAFAEL
│   ├── router.py      reglas rápidas
│   ├── llm.py         tool calling
│   └── registry.py    registro y despacho de skills
├── skills/            ← RAFAEL
│   ├── base.py        ← CONTRATO: interfaz Skill
│   ├── files.py       Everything / es.exe
│   ├── tasks.py       SQLite
│   ├── spotify.py     spotipy + SMTC + pycaw
│   └── system.py      hora, apps, volumen general
├── ui/                ← HEMSY
│   ├── console.py     salida rich (Fase 1)
│   ├── tray.py        icono de bandeja + estados (Fase 2)
│   └── hud/           HUD flotante (Fase 4)
│       ├── window.py  pywebview
│       └── web/        index.html · style.css · orb.js
├── tests/
│   ├── fixtures/audio/ WAVs de palmadas, ruido, voz
│   └── ...
├── config.yaml
├── .env
└── main.py            (gitignored)
```

5.6 Los dos contratos

Estos dos archivos son lo único que ambas personas necesitan acordar. Se escriben **juntos, en la primera sesión, antes que nada más**. Después cada uno trabaja en paralelo sin bloquear al otro.

core/events.py — cómo se comunican las capas:

```
@dataclass(frozen=True)
class WakeDetected:
    source: Literal["clap", "wakeword"]
    confidence: float
    timestamp: float

@dataclass(frozen=True)
class SpeechTranscribed:
    text: str
    language: str
    duration_s: float

@dataclass(frozen=True)
class SpeakRequested:
    text: str
    interruptible: bool = True
```

skills/base.py — cómo se declara una capacidad:


```

class Skill(Protocol):
    name: str # "spotify_play"
    description: str # lo que lee el LLM para decidir
    params_model: type[BaseModel] # esquema pydantic de los argumentos

    async def execute(self, params: BaseModel) -> SkillResult: ...

@dataclass
class SkillResult:
    ok: bool
    speech: str # lo que Jarvis dice en voz alta
    data: dict | None = None

```

El `Registry` recorre las skills registradas y genera automáticamente el array `tools` que se le manda a OpenAI, derivándolo de `params_model`. Así, **añadir una capacidad nueva es escribir una clase y nada más** — no hay que tocar el prompt ni el orquestador.

6. Organización del código

El sistema se divide en capas que se comunican **solo a través del bus de eventos**. Ninguna importa módulos de otra.

Carpeta	Responsabilidad	Módulos
<code>core/</code>	Eventos, bus, máquina de estados, config	<code>events</code> , <code>bus</code> , <code>state</code> , <code>config</code>
<code>ears/</code>	Del micrófono al texto	<code>capture</code> , <code>clap</code> , <code>wakeword</code> , <code>vad</code> , <code>stt</code>
<code>voice/</code>	Del texto al parlante	<code>base</code> , <code>piper_tts</code> , <code>edge_tts</code>
<code>ui/</code>	Lo que ve el usuario	<code>console</code> , <code>tray</code> , <code>hud</code>
<code>brain/</code>	De texto a decisión	<code>router</code> , <code>llm</code> , <code>registry</code>
<code>skills/</code>	Las capacidades	<code>files</code> , <code>tasks</code> , <code>spotify</code> , <code>system</code>

Esa separación no es cosmética: es lo que hace que **cada pieza se pueda testear sola**. El detector de palmadas se prueba con archivos WAV sin abrir el micrófono; las skills se prueban llamando `execute()` sin voz ni LLM; y el cerebro entero se prueba escribiendo por teclado con `--text-mode`.

`core/` **es lo único que hay que tocar con cuidado**. Todo depende de él, así que un campo nuevo en un evento puede romper cosas en silencio tres capas más abajo. Sus cambios van en commits propios, nunca mezclados con una feature.

7. Flujo de trabajo

Proyecto de una persona, así que nada de Pull Requests ni revisión cruzada. Pero tres hábitos siguen valiendo la pena, y no por ceremonia:

`main` **siempre funciona**. Si clonás y ejecutás, arranca. Cuando algo se rompe, querés poder volver a un punto conocido sin arqueología.

Una rama por tarea o por grupo chico de tareas.

```
git checkout main && git pull origin main
git checkout -b rafael/brain-tool-calling      # rafael/<área>-<qué>
# ...trabajar...
git checkout main && git merge --ff-only rafael/brain-tool-calling
git push origin main
```

La rama es una red: si a mitad de camino el enfoque resulta equivocado, se descarta entera sin ensuciar `main`.

Un commit por tarea del plan, en español y con prefijo de área (`feat(ears):` , `fix(brain):` , `docs:`). Merge con `--ff-only` para conservarlos: así `git log main` se lee como la lista de tareas hechas, que es exactamente lo que vas a querer consultar dentro de tres semanas cuando no te acuerdes por qué algo está como está.

Al cerrar cada fase: demo funcionando y `git tag fase-N`.

La regla que evita los dolores de verdad

Los cambios a `core/` van en su propio commit, nunca mezclados con una feature.

`core/events.py` es de lo que depende todo. Si un commit cambia un evento y añade una skill y toca el TTS, y algo empieza a fallar raro, no hay forma de bisecar. Separados, `git bisect` te dice exactamente dónde mirar.

Chuleta de emergencia

```
# Trabajé sobre main sin querer, aún sin commitear
git stash && git checkout -b rafael/lo-que-sea && git stash pop

# Committeé en main por error (aún sin push)
git branch rafael/rescate && git reset --hard origin/main && git checkout rafael/rescate

# Este enfoque no era, quiero tirar la rama entera
git checkout main && git branch -D rafael/lo-que-sea

# Subí algo secreto por error --> NO intentar arreglarlo solo:
# 1. Revocar la credencial YA (OpenAI / Spotify)
# 2. Generar una nueva
# 3. Después, limpiar el historial
```

Ese último caso es el único que es una emergencia real. **Borrar el commit no sirve: la clave ya se filtró en cuanto se subió.** El repositorio es público, así que el margen es de minutos. Primero revocar, después limpiar.

8. Fases

Cada fase termina en algo que funciona y se puede demostrar. No hay fase que entregue "la mitad de un pipeline".

Fase 0 — Contratos y esqueleto

Solo esto: `events.py` , `skills/base.py` , `config.py` , el bus, y `main.py --text-mode` con una skill de juguete (`ping` → responde "pong" por consola).

Terminada cuando: `python main.py --text-mode` , escribes `ping` , imprime `pong` . Es poco código, pero es lo que desbloquea todo el paralelismo posterior.

Fase 1 — "Escucha y responde" (primer corte vertical)

Conviene hacer el cerebro primero: se prueba entero con `--text-mode`, sin micrófono ni GPU. El audio se deja para después porque es donde las cosas fallan por motivos que no dependen del código.

Orden	Qué
1	<code>brain/registry.py</code> — registro y despacho de skills
2	<code>brain/router.py</code> — 5 reglas rápidas
3	<code>skills/system.py</code> — hora, fecha, saludo
4	<code>ears/capture.py</code> — micrófono y buffer circular
5	<code>ears/wakeword.py</code> — modelo "hey jarvis"
6	<code>ears/stt.py</code> — faster-whisper en GPU
7	<code>voice/piper_tts.py</code> — síntesis local
8	<code>ui/console.py</code> — estados y latencias en <code>rich</code>
9	Integración: <code>SkillResult.speech</code> → <code>SpeakRequested</code> → VOZ

Terminada cuando: decís "oye Jarvis, qué hora es" y responde en voz alta. **Todavía sin OpenAI.** Este hito ya es un producto usable, y es donde se descubren el 90% de los problemas reales (latencia, eco, ruido, dispositivos).

Fase 2 — El cerebro y las palmadas

Qué
<code>brain/llm.py</code> — tool calling contra OpenAI. Acá entra la API key, y no antes.
Manejo de errores y reintentos del LLM
<code>ears/clap.py</code> + dataset de fixtures de audio
<code>ears/vad.py</code> + endpointing (cortar cuando dejás de hablar)
Gate half-duplex durante <code>SPEAKING</code>
<code>ui/tray.py</code> — icono de bandeja con estados (§10)

Terminada cuando: doble palmada activa, una orden que ninguna regla cubre ("decime algo que me anime") llega al LLM y se resuelve, y **el icono de bandeja refleja el estado sin necesidad de mirar la terminal**. Desde este punto Jarvis se puede usar a diario, no solo demostrar.

Fase 3 — Las manos

Las skills que motivaron el proyecto:

- `skills/files.py` — Everything/ `es.exe`, con lista blanca de carpetas
- `skills/tasks.py` — SQLite: agregar, listar, completar pendientes
- `skills/spotify.py` — `SpotifyController` + implementación Free (search, startfile, SMTC, pycaw)

En paralelo:

- Afinar umbrales con datos reales de uso.

- Probar `medium` / `large-v3-turbo` de Whisper para ver si mejora la transcripción de nombres propios y títulos de canciones sin perder latencia.
- **Spike de transparencia de `pywebview`** (~30 min, riesgo R9). Decide si el HUD de la Fase 4 va en `WebView2` o cae a `Tkinter`. Hacerlo acá y no en Fase 4 evita descubrir el problema cuando ya hay HTML escrito.

Terminada cuando: los tres verbos del pedido original funcionan — *"ubicá la carpeta X"*, *"qué tengo pendiente"*, *"poné tal canción"* — y el spike del HUD tiene veredicto.

Fase 4 — HUD y pulido (cuando lo anterior esté sólido)

El HUD (§10): ventana flotante translúcida con orbe reactivo al nivel del micrófono, transcripción en vivo y respuesta. Antes de escribir el HTML, invocar la skill `ui-ux-pro-max` para fijar paleta, escala tipográfica, especificación de estados y motion. Recién en este punto tiene sentido: ya se sabe qué estados emite el bus de verdad.

Profundidad del cerebro: historial de conversación para preguntas de seguimiento (*"y la siguiente?"*), más skills (clima, notas, WhatsApp).

Y además: *barge-in* con cancelación de eco, y arranque automático con Windows.

9. Estrategia de testing

El problema obvio de un proyecto de voz es que parece que hay que hablarle a la computadora para probarlo. No es así, y evitarlo es lo que hace el desarrollo llevadero.

Capa	Cómo se testea	Sin necesidad de
<code>clap.py</code>	Fixtures WAV: 30 palmadas + 30 no-palmadas (portazos, teclado, risas, música). El test corre el detector y exige precision y recall mínimos.	Micrófono
<code>wakeword.py</code> , <code>vad.py</code>	Igual, con WAVs grabados una sola vez.	Micrófono
<code>stt.py</code>	WAVs conocidos, comparar con transcripción esperada.	Micrófono
<code>skills/*</code>	Llamar <code>execute()</code> directo con params contruidos a mano.	Voz, LLM
<code>router.py</code>	Tabla de frases → skill esperada. Rapidísimo.	Voz, LLM, red
<code>llm.py</code>	Cliente de OpenAI mockeado. Verificar que <i>"pon música triste"</i> produce <code>spotify_play(query=...)</code> .	Voz, red, créditos
End-to-end	<code>main.py --text-mode</code> con un script de comandos.	Micrófono

Lo primero que hay que hacer en la Fase 2 es grabar el dataset de fixtures. Media hora de grabar palmadas y ruidos convierte el ajuste del detector de "probar a ver qué pasa" en un ciclo medible de segundos.

10. Interfaz de usuario

Jarvis se maneja por voz, así que la interfaz no es el canal principal — es **retroalimentación de estado**. Su trabajo es responder una sola pregunta: *¿me está escuchando ahora mismo?* Sin eso le hablás a la nada y no sabés si te oyó.

Por eso la interfaz no es una decisión binaria sino una escalera de tres peldaños, y **el bus de eventos (§5.1) hace que subirlos sea gratis**: cualquier UI es un suscriptor más que escucha `WakeDetected`, `SpeechTranscribed` y los cambios de estado, y pinta. Añadir interfaz no obliga a refactorizar nada.

Peldaño 1 — Consola `rich` · Fase 1

Estado, transcripción y latencias en la terminal. Costo cero. Sirve para desarrollar y depurar; no sirve para usarlo a diario porque exige tener la terminal a la vista.

Peldaño 2 — Icono de bandeja · Fase 2 · obligatorio

`pystray` más notificaciones nativas de Windows. El icono cambia de color según el estado:

Estado	Color
<code>IDLE</code>	Gris
<code>LISTENING</code>	Azul (pulsante)
<code>THINKING</code> / <code>ACTING</code>	Ámbar
<code>SPEAKING</code>	Verde
Error	Rojo

Menú contextual con: pausar la escucha, recargar config, salir. Son ~150 líneas y es lo que convierte el proyecto de "script que corro en una terminal" a "algo que uso". **No es opcional en la práctica** — sin retroalimentación de estado, la experiencia se cae.

Peldaño 3 — HUD flotante · Fase 4

Ventana sin bordes, siempre encima, fondo transparente, arrastrable. Contiene un orbe que reacciona al nivel del micrófono en tiempo real, la frase transcrita mientras se procesa, y la respuesta de Jarvis. Aparece al activarse y se desvanece unos segundos después de responder — no vive permanentemente en pantalla.

Tecnología elegida: `pywebview` + **HTML/CSS/canvas**.

Opción	Veredicto
<code>pywebview</code> + HTML/CSS/canvas	Elegida. El orbe con glow, la onda de audio y las transiciones son casi triviales en CSS y canvas, y dolorosas en Qt. Usa WebView2, ya instalado en Windows 11.
<code>PySide6</code> / <code>PyQt6</code>	Nativo y potente, pero muy verboso; cada animación decente cuesta trabajo real.
<code>Tkinter</code>	Fallback probado. Su opción <code>-transparentcolor</code> de Windows funciona con seguridad. Se ve bastante peor, pero no tiene dependencias.

Spike obligatorio antes de comprometerse (Fase 3, ~30 min): la transparencia real de ventana sobre WebView2 tiene fama de ser inconsistente entre versiones. Hay que verificar que `transparent=True` + `frameless=True` + `on_top=True` se comportan en esta máquina **antes** de escribir el HUD. Si no se porta, se cae a Tkinter y se ajustan

las expectativas visuales. El resultado del spike se anota acá mismo.

Diseño visual: cuando se arranque el HUD, usar la skill `ui-ux-pro-max` para definir paleta, escala tipográfica, especificación de estados y motion. Invocarla en ese momento y no antes: necesita saber qué estados reales emite el bus para que la especificación sirva de algo. Dirección estética de partida: oscuro, translúcido, acento cian, glow suave, tipografía condensada — el registro visual de Iron Man sin caer en la parodia.

Lo que queda fuera

Una web UI completa (FastAPI + WebSocket + React, con panel de historial, gestión de tareas y configuración) queda descartada. Es un proyecto en sí mismo y no aporta nada a un asistente que se maneja por voz. Si algún día quieren un panel de administración, es un segundo producto, no parte de este.

Por qué el HUD va al final

El HUD va en la Fase 4 y no antes por una razón práctica: el orbe se anima con el nivel de audio en tiempo real del buffer de captura, así que necesita que `ears/` esté terminado y estable. Construirlo contra un pipeline que todavía cambia es hacerlo dos veces.

11. Riesgos y mitigaciones

#	Riesgo	Probabilidad	Mitigación
R1	cuDNN/cuBLAS: <code>faster-whisper</code> en GPU falla en Windows por DLLs faltantes. Es el problema clásico de este stack.	Alta	<code>pip install nvidia-cublas-cu12 nvidia-cudnn-cu12</code> y añadir sus <code>lib/</code> con <code>os.add_dll_directory()</code> al arrancar. Fallback automático a <code>device="cpu", compute_type="int8"</code> , que igual funciona (más lento). Probar esto en la Fase 1, no al final.
R2	El wake word "hey jarvis" no reconoce acento español. El modelo pre-entrenado se entrenó con voces en inglés.	Media	Escalera de mitigación: (a) probarlo el primer día de la Fase 1; (b) si falla, <code>openWakeWord</code> trae un notebook de entrenamiento gratuito que genera miles de muestras sintéticas con Piper — se puede entrenar "oye Jarvis" en español; (c) último recurso: activación solo por palmada.
R3	Falsos positivos de palmadas con portazos, teclado mecánico, aplausos en un video.	Media	Doble palmada + filtro de decaimiento + planitud espectral + periodo refractario. Se mide contra el dataset de fixtures, no a ojo.
R4	Eco del TTS re-dispara el wake word y hace bucle.	Alta si no se maneja	Gate half-duplex en el estado <code>SPEAKING</code> (§5.4). Es una línea de lógica y resuelve el caso por completo en v1.
R5	Spotify Free ignora el track y hace shuffle, más los anuncios.	Alta	Aceptado y documentado. Interfaz <code>SpotifyController</code> deja la puerta abierta a Premium sin refactor.
R6	Teclas multimedia capturadas por el navegador en lugar de Spotify.	Media	Por eso usamos SMTC dirigido a la sesión de Spotify por <code>AppUserModelId</code> , y no <code>keybd_event</code> global.
R7	El LLM alucina una skill que no existe o manda params inválidos.	Media	Validación pydantic antes de ejecutar; si falla, se devuelve el error al modelo para un reintento, con máximo 2 vueltas y luego una disculpa hablada.
R8	Comandos accidentales desde audio ambiente (un video, una visita).	Media	Catálogo de herramientas sin operaciones destructivas. Lista blanca de carpetas para <code>files</code> . Nada de shell arbitrario. Ver §1.

#	Riesgo	Probabilidad	Mitigación
R9	Transparencia de ventana en <code>pywebview</code> / <code>WebView2</code> inconsistente entre versiones — el HUD sale con fondo negro en vez de translúcido.	Media	Spike de ~30 min en Fase 3 , antes de escribir una línea de HTML. Si falla, fallback a Tkinter con <code>-transparentcolor</code> , que sí funciona con seguridad en Windows, aceptando un resultado visual más pobre. El HUD es Fase 4 y no bloquea nada anterior.

12. Checklist de arranque

Antes de escribir la primera línea:

- ☐ Crear el repo e invitar a la otra persona
- ☐ `py -3.11 -m venv .venv` (Python 3.11, no 3.13 ni 3.14)
- ☐ Instalar [Everything](#) y habilitar la CLI `es.exe` en el PATH
- ☐ Crear la app en el [Spotify Developer Dashboard](#) → Client ID y Secret
- ☐ Cargar los \$5 en la cuenta de OpenAI y generar la API key
- ☐ `.env` con `OPENAI_API_KEY`, `SPOTIFY_CLIENT_ID`, `SPOTIFY_CLIENT_SECRET` — y `.env` en `.gitignore` desde el primer commit
- ☐ Identificar el índice del array de micrófono interno con `python -m sounddevice` y fijarlo en `config.yaml`
- ☐ `openwakeword.utils.download_models()` para bajar los modelos pre-entrenados
- ☐ Descargar una voz de Piper en español (`es_MX-claude-high` o `es_ES-davefx-medium`)

13. Decisiones tomadas y descartadas

Decisión	Elegido	Descartado	Razón
Dónde vive la inteligencia	Local-first, LLM solo como enrutador	OpenAI Realtime API (voz a voz)	Realtime cobra por token de audio , ~2 órdenes de magnitud más caro. Los \$5 darían para ~40-60 minutos totales de conversación.
Entendimiento de intención	LLM + router de reglas por delante	Solo reglas (regex/fuzzy)	Sin LLM no entiende <i>"ponme algo tranquilo para estudiar"</i> . Deja de sentirse como Jarvis y se siente como un menú telefónico.
Transcripción	<code>faster-whisper</code> local en GPU	Whisper API de OpenAI	La 4050 lo hace gratis y más rápido que subir el audio. La API costaría \$0.006/min.
Activación	Doble palmada + wake word	Palmada simple	Una palmada suelta se confunde con un portazo.
Control de Spotify	SMTC dirigido	Teclas multimedia globales	Las globales se las roba el navegador si está reproduciendo video.
Almacenamiento de tareas	SQLite local	Google Tasks / Todoist API	YAGNI. Cero setup, cero auth, funciona offline. Se puede sincronizar después.
Búsqueda de archivos	Everything + <code>es.exe</code>	Windows Search / <code>os.walk</code>	Everything responde en milisegundos indexando la MFT.

Decisión	Elegido	Descartado	Razón
Duplex del audio	Half-duplex (no escucha mientras habla)	Cancelación de eco acústica	AEC real es un proyecto en sí mismo. El gate resuelve el 100% del problema en v1.
Interfaz	Escalera: consola → bandeja → HUD	Elegir una sola de entrada	El bus de eventos hace que cada peldaño sea aditivo y sin refactor. No hay que decidirlo hoy.
Tecnología del HUD	<code>pywebview</code> + HTML/CSS/canvas	PySide6 / Qt · Tkinter	El orbe con glow y la onda de audio son triviales en CSS y dolorosas en Qt. Tkinter queda como fallback probado si el spike R9 falla.
Panel de administración	Ninguno	Web UI con FastAPI + React	Es un segundo producto. No aporta nada a un asistente que se maneja por voz.

14. Respuestas directas a las preguntas iniciales

¿Basta gpt-4o-mini? Sí, de sobra. La tarea es clasificación de intención con extracción de parámetros. Con la arquitectura local-first, los \$5 alcanzan para ~21,000 comandos, cerca de 2 años de uso normal entre dos personas.

¿Los \$5 de OpenAI son la única inversión? Sí. Todo el resto del stack es open source o freeware. El único costo adicional es ~2-3 GB de disco para los modelos. La salvedad no es de dinero sino de funcionalidad: con Spotify Free el control de reproducción va por SMTC y `startfile` en vez de por la API, con anuncios y shuffle ocasional (\$3).

¿Cómo se divide el trabajo entre dos? El proyecto lo hace una sola persona. El código se organiza en capas que se comunican solo por el bus de eventos (§6) — no para repartir trabajo, sino porque es lo que hace que cada pieza se pueda testear sola y que `--text-mode` permita depurar el cerebro sin micrófono.